

Reporte Ejecutivo

Proyecto Final — Machine Learning con PySpark y Docker

Universidad Santo Tomás · Programa de Estadística · 2026-I

Kevin Leonardo Chaparro Reyes

Profesora: Luz Adriana Gutiérrez Rodríguez

1. Resumen ejecutivo

Se analizó la contratación pública colombiana mediante datos del SECOP II (52,832 contratos de 2026) y el sentimiento en reseñas de aplicaciones financieras colombianas (2,316 reseñas de Nequi, Bancolombia y Rappi). El proyecto integra análisis exploratorio, aprendizaje supervisado y no supervisado con PySpark, y procesamiento de lenguaje natural con modelos clásicos y pre-entrenados. Los resultados muestran que la modalidad de contratación pública es altamente predecible (95 % accuracy) a partir de factores institucionales, y que el sentimiento en reseñas puede clasificarse con más del 90 % de precisión incluso con métodos basados en frecuencia de términos.

2. Metodología

Bloque 1 — Análisis Exploratorio con PySpark

Se descargaron 60,000 contratos del SECOP II mediante la API Socrata de datos.gov.co, seleccionando 18 variables de 84 disponibles. Tras eliminar 7,168 duplicados exactos, se trabajó con 52,832 registros. Se aplicaron cuatro transformaciones de PySpark (`filter`, `groupBy`, `withColumn`, `join`), estadística descriptiva con análisis de asimetría y curtosis, detección de atípicos mediante criterio IQR, y una prueba de Mann-Whitney para comparar valores entre modalidades de contratación.

Bloque 2 — Machine Learning con Spark ML

Se definió como variable objetivo una clasificación binaria de la modalidad de contratación: directa/régimen especial (58.6 %) versus proceso competitivo (41.4 %). Se construyó un pipeline de preparación con `StringIndexer`, `OneHotEncoder`, `VectorAssembler` y `StandardScaler`, generando 97 features. Se aplicó PCA (7 componentes, 17.6 % de varianza) y K-Means ($K = 5$, Silhouette 0.39) como análisis no supervisado. Para clasificación se entrenaron Regresión Logística y Random Forest, optimizando este último con `CrossValidator` (5 folds, 9 combinaciones de hiperparámetros). El pipeline de preparación se ajustó exclusivamente sobre el conjunto de entrenamiento para evitar *data leakage*.

Bloque 3 — NLP y modelo pre-entrenado

Se recopilaron 2,316 reseñas de Google Play Store de tres aplicaciones financieras colombianas mediante la librería `google-play-scraper`. Se definió sentimiento binario a partir de las estrellas (1-2: negativo, 4-5: positivo; 3 estrellas excluidas). Se aplicó tokenización con soporte para tildes y ñe (`RegexTokenizer`), filtrado de *stop words*, y vectorización TF-IDF (1,056 términos). Se entrenó una Regresión Logística sobre los vectores TF-IDF y se comparó con el modelo pre-entrenado `robertuito-sentiment-analysis` de Hugging Face, evaluando ambos sobre el mismo conjunto de test.

3. Resultados clave

Bloque 1 — Contratación pública: estructura y concentración

El 58.6 % de los contratos se adjudican sin competencia abierta. La mediana de valor en contratos directos (17.3 millones COP) es significativamente menor que en competitivos (42.3 millones COP; Mann-Whitney, $p < 0.001$). La distribución de valores presenta asimetría de 72.94 y coeficiente de variación de 1,214.9 %, confirmando una cola pesada severa con el 16.2 % de los contratos clasificados como atípicos por criterio IQR.




Figura 1: Distribución del valor de contratos por modalidad. Archivo: bloque1.eda/fig1_distribucion_modalidad.png

Bloque 2 — Predicción de modalidad de contratación

El Random Forest optimizado alcanza un accuracy de 95.0 % y un AUC de 0.989 (diferencia train-test de 0.27 puntos porcentuales, descartando sobreajuste). Las tres variables más predictivas concentran el 78.6 % de la importancia total: sector (32.8 %), si el proveedor es PYME (27.2 %) y tipo de contrato (18.5 %). K-Means reveló cinco perfiles de contratación diferenciados, desde contratos pequeños de salud bajo régimen especial (96.2 % directa, mediana 12.5M) hasta licitaciones de servicios públicos (78.4 % competitiva, mediana 46.2M).

Modelo	Accuracy	F1	AUC
Regresión Logística	0.930	0.930	0.978
Random Forest (base)	0.938	0.938	0.982
RF + CrossValidator (mejor)	0.950	—	0.989

Cuadro 1: Comparación de modelos supervisados — Bloque 2.

Bloque 3 — Sentimiento en reseñas financieras

Sobre el mismo conjunto de test (280 documentos evaluables), robertuito alcanza 96.1 % de accuracy frente al 91.4 % de TF-IDF + Regresión Logística. Sin embargo, robertuito clasifica el 31 % del test como neutro sin emitir predicción binaria, mientras que TF-IDF ofrece cobertura total. Las palabras más predictivas de sentimiento positivo son “excelente” (+1.05) y “buena” (+0.87); las negativas son “porquería” (−0.78), “estafadores” (−0.67) y “pésimo” (−0.66).

Modelo	Accuracy	F1
TF-IDF + LogReg (PySpark)	0.914	0.914
robertuito (Hugging Face)	0.961	0.961

Cuadro 2: Comparación sobre el mismo test set (280 docs) — Bloque 3.

4. Reflexión integradora

Los tres bloques demuestran que los datos públicos colombianos contienen patrones estructurales claros y explotables. En contratación pública, la modalidad de adjudicación no es aleatoria sino predeterminada en gran medida por el sector institucional y el tipo de contrato, reflejando el marco regulatorio vigente. En el ecosistema financiero digital, el sentimiento de los usuarios es capturado tanto por métodos clásicos de frecuencia de términos como por modelos pre-entrenados de lenguaje, aunque cada enfoque presenta fortalezas distintas: TF-IDF ofrece interpretabilidad total y cobertura completa, mientras que robertuito captura mejor las relaciones semánticas a costa de mayor complejidad computacional y menor cobertura. La conexión entre ambos dominios radica en que tanto el gasto público como la percepción ciudadana de los servicios financieros revelan dinámicas institucionales que pueden ser analizadas cuantitativamente con las herramientas del curso.

5. Limitaciones

- El corpus de reseñas tiene una mediana de 5 palabras por documento, lo que limita la capacidad de TF-IDF para capturar contexto semántico más allá de señales léxicas directas.
- PCA sobre variables categóricas codificadas con OneHotEncoder distribuye la varianza de forma dispersa (20 componentes capturan solo 34.6 %), lo que reduce su utilidad como técnica de reducción de dimensionalidad en este contexto.
- Las calificaciones en estrellas no siempre reflejan el sentimiento real del texto (etiquetas ruidosas), lo que introduce ruido en la evaluación de ambos modelos de NLP.
- El dataset SECOP II contiene solo contratos de 2026 (febrero-mayo), lo que limita la generalización temporal.
- Daviplata no devolvió reseñas en el scraping, reduciendo la diversidad del corpus a tres aplicaciones.

6. Recomendaciones

- Para replicar este análisis se sugiere ampliar el rango temporal del SECOP II y diversificar las fuentes de reseñas para reducir el sesgo hacia quejas de delivery (dominadas por Rappi).
- Un enfoque híbrido que combine TF-IDF para clasificación rápida y robertuito para validación de casos ambiguos podría mejorar la cobertura sin sacrificar precisión.
- La detección de etiquetas ruidosas (discrepancia entre calificación numérica y contenido textual) es un problema relevante que podría abordarse como un proyecto de investigación por sí mismo.